

Diseño de algoritmo para la segmentación del disco óptico en imágenes de fondo de retina

Cristian Javier Gómez Montaña
Universidad Industrial de Santander
2144271

Abstract—El glaucoma es la principal causa de ceguera irreversible en el mundo. Su carácter crónico y silencioso dificulta la detección temprana. La segmentación del disco óptico en imágenes de fondo de retina se considera el paso preliminar en el desarrollo de la herramienta de diagnóstico para la detección temprana del glaucoma. En este trabajo se desarrolló un modelo de segmentación automática basado en la arquitectura U-Net, utilizando imágenes de retina de la base de datos pública de Origa-ligth. Para mejorar la capacidad del modelo, se aplicaron técnicas de aumento de datos y se evaluó su rendimiento mediante el coeficiente de similitud de Dice (DSC) y la intersección sobre la unión (IoU). Experimentos con conjunto de prueba de 650 imágenes muestran que el modelo consiguió una IoU de 0.568 y un DSC de 0.721.

Index Terms—

I. INTRODUCCIÓN

El glaucoma es la principal causa de ceguera irreversible en el mundo. Su carácter crónico y silencioso dificulta la detección temprana, lo que genera un alto impacto en la salud pública y en la calidad de vida de los pacientes. Según la Organización Mundial de la Salud (OMS), en el año 2020 se reportaron en el mundo, 295 millones de personas con baja visión y 43 millones con ceguera, afectando al 3% de toda la población colombiana, con un aumento del 10% entre la población mayor de 40 años. Un oftalmólogo especializado en glaucoma (glaucomatólogo) puede llegar a detectar la enfermedad en menos de 30 minutos[1].

EL Glaucoma es una enfermedad asociada con el cambio de presión ocular afectando el nervio óptico. Este está conformado por fibras nerviosas encargadas de enviar los mensajes visuales al cerebro, produciendo la pérdida de visión y posible ceguera[2]. Un método para detectar el avance del glaucoma consiste en la detección de anomalías en el disco óptico (DO) en imágenes de fondo de retina, que son fotografías de la superficie interior del ojo [3] como se muestra en la figura 1.

En este contexto, el desarrollo de métodos computacionales para la segmentación del DO resulta fundamental, ya que permite apoyar el diagnóstico oportuno y contribuir a la prevención de la progresión de la enfermedad. Para realizar la segmentación del DO se empleaban métodos manuales y técnicas clásicas de procesamiento de imágenes, los cuales presentaban ciertas limitaciones ante variaciones de iluminación, ruido y diferencias anatómicas. Con la aparición de técnicas de *Machine Learning* y *Deep Learning*, se

han desarrollado métodos mas avanzados para el análisis y segmentación de imágenes médicas, mejorando los resultados en la detección del glaucoma [4].

La U-Net, es una de las arquitecturas de redes neuronales convolucionales (CNN) más sólidas, versátiles y efectivas para la segmentación de imágenes biomédicas, ya que mantiene un equilibrio entre precisión y eficiencia, siendo más accesible en términos de entrenamiento y recursos de hardware[5]. Su diseño basado en un encoder – decoder con conexiones de salto, permite recuperar información espacial de alta resolución logrando delinear con mayor precisión estructuras pequeñas y complejas como el DO.

En base a esto, se propone un método de segmentación del DO basado en la arquitectura U-Net, en el conjunto de base de datos de *Origa (Ligth)* [6], al cual se le realiza un preprocesamiento aplicando operaciones morfológicas y estandarización en las imágenes. En este documento se describe el proceso de diseño e implementación de la red neuronal, y se reportan los resultados experimentales de desempeño.




Fig. 1: Localización del disco óptico en imagen de fondo de ojo de retina .

II. TRABAJOS PREVIOS

Antes de la aparición de los algoritmos basados en aprendizaje profundo (*Deep Learning*), la segmentación del disco óptico se realizaba mediante diferentes procesamiento aplicados a las imágenes de fondo de retina. Uno de los métodos más comunes era la clasificación de superpíxeles, donde se utilizaban histogramas y estadísticas del centro y su entorno para determinar si cada superpíxel correspondía o no al disco óptico. De esta manera, se lograba extraer características como apariencia, ubicación, textura y color, que permitían diferenciar la región del disco de la región no discal [7].

En [8] se propone una técnica jerárquica para la localización y segmentación precisa del disco óptico, realizando un preprocesamiento de las imágenes para eliminar los vasos sanguíneos y las patologías de la retina mediante operaciones morfológicas. Posteriormente, se localiza el disco óptico con la transformada de Hough y un umbral adaptativo basado en la transformada polar.

Con la aplicación de *Deep Learning* surgieron distintas arquitecturas para la segmentación del disco óptico. En [9] se presenta un enfoque universal basado en la modificación de la red neuronal U-Net, realizando un preprocesamiento de ecualización adaptativa del histograma con contraste limitado (CLAHE), que mejora el contraste modificando el color de las regiones de la imagen. Asimismo, la arquitectura M-Net [10] propone una capa de entrada multi-escala, una red convolucional en forma de U y la transformación polar de la imagen de fondo de ojo. En este caso, primero se localiza el centro del disco utilizando un método de detección automática de discos; luego, se transforma la imagen al sistema de coordenadas polares para introducirla a la M-Net y finalmente generar mapas de probabilidad.

Por su parte, la red CE-Net (*Context Encoder Network*) [11] que contiene tres componentes principales —un módulo codificador de características basado en una ResNet preentrenada, un extractor de contexto formado por un bloque de convolución densa *atrous*, y un módulo decodificador de características— ha logrado resultados competitivos respecto a la arquitectura original de U-Net.

Los métodos tradicionales de segmentación del disco óptico ofrecieron resultados aceptables en condiciones controladas, pero su precisión disminuía ante variaciones de iluminación, contraste o presencia de patologías en la retina. Con el surgimiento del *Deep Learning*, se logró mejorar significativamente la segmentación al eliminar la dependencia de características manuales y permitir una extracción automática de patrones complejos. No obstante, muchos estudios previos se limitan a evaluar arquitecturas básicas o sin optimizaciones específicas para el disco óptico.

En este sentido, resulta necesario continuar explorando y modificando redes neuronales como la U-Net, con el fin de optimizar la segmentación del disco óptico y aportar a un análisis más preciso de las imágenes de fondo de retina.

III. MÉTODOS Y MATERIALES

A. Base de datos

Para el desarrollo del proyecto se utilizó la base de datos pública de *Origa-ligth* que contiene 650 imágenes de fondo de ojo de retina con anotaciones de profesionales formados del Instituto de Investigación Ocular de Singapur [6]. El tamaño de las imágenes es aproximadamente de 2548x2048 píxeles en formato RGB. Se realiza un preprocesamiento a las imágenes para extraer una región de interés adaptando el tamaño de dichas imágenes a 128x128 píxeles. El entrenamiento y la evaluación del modelo se realizaron en *Google Colab*, aprovechando al máximo sus recursos en cómputo en la nube (GPU) y su compatibilidad con bibliotecas como Tensorflow y Keras.

B. Arquitectura de segmentación

La arquitectura empleada corresponde a una red U-Net basada en la implementación del repositorio Optic-Nerve[12]. En este trabajo se entrenó el modelo desde cero utilizando la base de datos Origa-ligth, con el propósito de adaptar la red a las características específicas de las imágenes de fondo de retina. En la figura 2 se muestra la arquitectura de la red neuronal. Esta red presenta una estructura simétrica compuesta por dos partes principales: un codificador (encoder) y un decodificador (decoder), conectados mediante un bloque intermedio (bridge). En el encoder, la red extrae características más abstractas mediante capas de convolución seguidas de una normalización (batchnormalization) y funciones de activación ReLU, reduciendo la dimensionalidad a través de capas de max pooling. El bloque bridge actúa como una capa de conexión que consolida la característica de mayor nivel obtenidas por el encoder.

El decoder realiza un proceso inverso: utiliza capas de upsampling y deconvolución para recuperar la resolución espacial, combinando las características obtenidas por el encoder, lo que permite conservar la información estructural importante. Adicional a esto, se incorporó un bloque de aumento de datos (*data augmentation*), que aplica transformaciones aleatorias como giros, rotaciones y cambios de contraste, con el fin de mejorar la generalización del modelo y reducir el riesgo de sobreajuste.

C. Entrenamiento y selección de hiperparámetros

El modelo fue entrenado utilizando el optimizador Adam, el cual reajusta los pesos de manera adaptativa para acelerar la convergencia y mejorar la estabilidad del entrenamiento. Como función de pérdida se empleó *binary cross-entropy*, adecuada para las tareas de segmentación binaria, siendo ideal para distinguir entre las regiones correspondientes al disco óptico y el fondo de la imagen. Para prevenir el sobreajuste, se implementó la técnica de *Earling Stopping*, el cual detiene el entrenamiento si la pérdida de validación no muestra una mejora después de cinco épocas consecutivas. Se dividió la base de datos en 325 imágenes para test y 325 imágenes para *train/validation*, con una proporción de 80% de train y 20% de validation durante un máximo de 20 épocas.




Fig. 2: Arquitectura de la red neuronal empleada en nuestro método.

D. Medidas de desempeño

Para evaluar el desempeño del modelo de segmentación, se utilizaron diferentes métricas que permiten medir su precisión y capacidad de generación las cuales fueron la exactitud o *accuracy* (A), sensibilidad o *sensitivity* (Sen), especificidad o *specifity* (Spe), intersección sobre unión o *Intersection over Union* (IoU) y el coeficiente de Dice o *Dice Coefficient* (Dice), que se definen como:

$$A = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Sen = \frac{TP}{TP + FN}$$

$$Spe = \frac{TN}{TN + FP}$$

$$IoU = \frac{TP}{TP + FP + FN}$$

$$Dice = \frac{2(TP)}{2(TP) + FP + FN}$$

en donde TP son los verdaderos positivos (*True Positive*), TN son verdaderos negativos (*True Negative*), FP son falsos positivos (*False Positive*) y FN los falsos negativos (*False Negative*).

IV. RESULTADOS

En la tabla I, se ilustran los valores finales de las métricas de desempeño del modelo de U-Net. El modelo alcanzó una exactitud de 0.99 en el entrenamiento, un 0.98 en validación y prueba, se alcanzó un coeficiente de Dice promedio de 0.767, 0.749 y 0.721 respectivamente lo que indica una buena superposición entre la predicción. En la métrica de IoU se obtiene un 0.624, 0.602 y 0.568 respectivamente reflejando una segmentación consistente. Para la sensibilidad se alcanzó un 0.82 para entrenamiento, 0.89 para validación y un 0.74 para prueba y en cuanto a la especificidad un 0.99, 0.99 y 0.99 respectivamente.

En la figura 3 se muestra la distribución del coeficiente de Dice alcanzado durante el entrenamiento del modelo. La mayoría de los valores se concentran entre 0.7 y 0.8, lo que indica que el modelo logró un nivel de solapamiento alto entre las segmentaciones predichas y las máscaras reales. Solo unos pocos valores se encuentran por debajo de 0.5, lo que sugiere

que el entrenamiento fue consistente y que el modelo aprendió progresivamente a segmentar de manera más precisa.




Fig. 3: Histograma de los coeficientes de Dice.

Los resultados de la segmentación se muestran en la figura 4, el límite del disco óptico detectado por la metodología propuesta se muestra en la tercera imagen donde la región blanca corresponde al disco óptico detectado y en la cuarta imagen se muestra la segmentación final.

En la Tabla II se presentan los resultados de desempeño del modelo propuesto en comparación con otros métodos de segmentación del disco óptico. Aunque la sensibilidad obtenida fue menor respecto a algunos trabajos, las métricas de especificidad y exactitud reflejan un modelo robusto con una buena capacidad para evitar falsos positivos. Cabe aclarar que esta comparación se incluye únicamente con fines de discusión, ya que los experimentos reportados en los diferentes estudios no fueron realizados bajo las mismas condiciones ni con las mismas bases de datos, por lo que los resultados no son estrictamente equivalentes.

TABLE II: Comparación de métricas de desempeño con otros métodos de segmentación del disco óptico.

Método	Acc	Sen	Spe	IoU	Dice
Fast Optic Disc[8]	0.9986	0.9384	0.9994	-	-
Disc-Aware[5]	-	0.8478	0.8380	-	-
Optic Disc[9]	-	-	-	0.8900	0.9400
CE-Net[11]	0.9904	0.9800	-	-	-
Nuestro método	0.9893	0.7401	0.9976	0.5684	0.7217

TABLE I: Resultados de las métricas de desempeño del modelo U-Net durante el entrenamiento, validación y prueba.

Dataset	Acc	Dice	IoU	Sen	Spe	Loss
Entrenamiento	0.9912	0.7673	0.6241	0.8231	0.9966	0.0218
Validación	0.9893	0.7491	0.6029	0.8926	0.9933	0.0269
Prueba (Test)	0.9889	0.7217	0.5684	0.7401	0.9976	0.0277




Fig. 4: Resultados de la segmentación. De izquierda a derecha: Imagen original, mascara real, predicción y la segmentación final.

V. CONCLUSIONES Y DISCUSIÓN

El modelo basado en la arquitectura U-Net mostró un buen desempeño en la segmentación del disco óptico, logrando resultados consistentes tanto en el entrenamiento como en la validación. Las métricas obtenidas de exactitud, sensibilidad, especificidad, intersección sobre unión y coeficiente de Dice, indican que el modelo fue capaz de identificar de manera precisa la región del disco óptico.

Al comparar los resultados con otros trabajos, se observa que el modelo propuesto alcanza valores de exactitud y especificidad muy cercanos a los de arquitecturas más complejas como Fast Optic Disc y CE-Net. No obstante, la sensibilidad fue un poco más baja, lo que sugiere que en algunos casos el modelo podría no detectar por completo el área del disco. Esto puede deberse a la variación en las imágenes utilizadas, la cantidad de datos disponibles o las características del preprocesamiento.

Aun así, los resultados confirman que la U-Net es una opción efectiva y equilibrada para este tipo de segmentación, combinando buen rendimiento y bajo costo computacional. Para mejorar el modelo, sería recomendable aplicar un aumento de datos más amplio, probar otras funciones de pérdida o incluir mecanismos de atención que ayuden a resaltar mejor los bordes del disco.

En general, el modelo desarrollado ofrece una base sólida para futuras investigaciones y representa un paso importante hacia el desarrollo de herramientas automáticas de apoyo en la detección de enfermedades oculares como el glaucoma.

REFERENCES

- [1] 12 de marzo: día del glaucoma, la causa principal de la ceguera. "Instituto nacional para ciegos – inci, equipo comunicaciones." [Accesed: September 21, 2025]. (2023), [Online]. Available: <https://www.inci.gov.co/blog/12-de-marzo-dia-del-glaucoma>
- [2] Y.-C. Tham, X. Li, T. Y. Wong, H. A. Quigley, T. Aung, and C.-Y. Cheng, "Global prevalence of glaucoma and projections of glaucoma burden through 2040: A systematic review and meta-analysis," *Ophthalmology*, vol. 121, no. 11, pp. 2081–2090, 2014, ISSN: 0161-6420. DOI: <https://doi.org/10.1016/j.ophtha.2014.05.013>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S0161642014004333>.
- [3] F. C. de Glaucoma. "¿qué es glaucoma?" [Accesed: September 21, 2025]. (2024), [Online]. Available: <http://www.glaucoma.org.co/articulos/que-es-glaucoma>.
- [4] Y. Jiang, L. Duan, J. Cheng, *et al.*, "Jointtrcnn: A region-based convolutional neural network for optic disc and cup segmentation," *IEEE Transactions on Biomedical Engineering*, vol. 67, no. 2, pp. 335–343, 2020. DOI: 10.1109/TBME.2019.2913211.
- [5] H. Fu, J. Cheng, Y. Xu, *et al.*, "Disc-aware ensemble network for glaucoma screening from fundus image," *IEEE Transactions on Medical Imaging*, vol. 37, no. 11, pp. 2493–2501, 2018. DOI: 10.1109/TMI.2018.2837012.
- [6] sshikamaru, *Glaucoma detection*, <https://www.kaggle.com/datasets/sshikamaru/glaucoma-detection>, Kaggle dataset, 2020.
- [7] J. Cheng, J. Liu, Y. Xu, *et al.*, "Superpixel classification based optic disc and optic cup segmentation for glaucoma screening," *IEEE Transactions on Medical Imaging*, vol. 32, no. 6, pp. 1019–1032, 2013. DOI: 10.1109/TMI.2013.2247770.
- [8] M. N. Zahoor and M. M. Fraz, "Fast optic disc segmentation in retina using polar transform," *IEEE Access*, vol. 5, pp. 12 293–12 300, 2017. DOI: 10.1109/ACCESS.2017.2723320.
- [9] A. Sevastopolsky, "Optic disc and cup segmentation methods for glaucoma detection with modification of u-net convolutional neural network," *Pattern Recognition and Image Analysis*, vol. 27, no. 3, pp. 618–624, 2017, ISSN: 1054-6618.
- [10] H. Fu, J. Cheng, Y. Xu, D. W. K. Wong, J. Liu, and X. Cao, "Joint optic disc and cup segmentation based on multi-label deep network and polar transformation," *IEEE Transactions on Medical Imaging*, vol. 37, no. 7, pp. 1597–1605, 2018. DOI: 10.1109/TMI.2018.2791488.
- [11] Z. Gu, J. Cheng, H. Fu, *et al.*, "Ce-net: Context encoder network for 2d medical image segmentation," *IEEE Transactions on Medical Imaging*, vol. 38, no. 10, pp. 2281–2292, 2019. DOI: 10.1109/TMI.2019.2903562.
- [12] ssykira, *Optic-nerve*, <https://github.com/ssykira/optic-nerve>, GitHub repository.

VI. ANEXOS

TABLE III: Resumen de las capas y dimensiones de salida del modelo U-Net

Layer (type)	Output Shape
InputLayer	(None, 128, 128, 3)
Conv2D	(None, 128, 128, 64)
BatchNormalization	(None, 128, 128, 64)
Activation	(None, 128, 128, 64)
Conv2D_1	(None, 128, 128, 64)
BatchNormalization_1	(None, 128, 128, 64)
Activation_1	(None, 128, 128, 64)
MaxPooling2D	(None, 64, 64, 64)
Conv2D_2	(None, 64, 64, 128)
BatchNormalization_2	(None, 64, 64, 128)
Activation_2	(None, 64, 64, 128)
Conv2D_3	(None, 64, 64, 128)
BatchNormalization_3	(None, 64, 64, 128)
Activation_3	(None, 64, 64, 128)
MaxPooling2D_1	(None, 32, 32, 128)
Conv2D_4	(None, 32, 32, 256)
BatchNormalization_4	(None, 32, 32, 256)
Activation_4	(None, 32, 32, 256)
Conv2D_5	(None, 32, 32, 256)
BatchNormalization_5	(None, 32, 32, 256)
Activation_5	(None, 32, 32, 256)
MaxPooling2D_2	(None, 16, 16, 256)
Conv2D_6	(None, 16, 16, 512)
BatchNormalization_6	(None, 16, 16, 512)
Activation_6	(None, 16, 16, 512)
Conv2D_7	(None, 16, 16, 512)
BatchNormalization_7	(None, 16, 16, 512)
Activation_7	(None, 16, 16, 512)
MaxPooling2D_3	(None, 8, 8, 512)
Conv2D_8	(None, 8, 8, 1024)
BatchNormalization_8	(None, 8, 8, 1024)
Activation_8	(None, 8, 8, 1024)
Conv2D_9	(None, 8, 8, 1024)
BatchNormalization_9	(None, 8, 8, 1024)
Activation_9	(None, 8, 8, 1024)
Conv2DTranspose	(None, 16, 16, 512)
Concatenate	(None, 16, 16, 1024)
Conv2D_10	(None, 16, 16, 512)
Conv2DTranspose_1	(None, 32, 32, 256)
Concatenate_1	(None, 32, 32, 512)
Conv2D_12	(None, 32, 32, 256)
Conv2DTranspose_2	(None, 64, 64, 128)
Concatenate_2	(None, 64, 64, 256)
Conv2D_14	(None, 64, 64, 128)
Conv2DTranspose_3	(None, 128, 128, 64)
Concatenate_3	(None, 128, 128, 128)
Conv2D_16	(None, 128, 128, 64)
Conv2D_18	(None, 128, 128, 1)